

利用显示缓存为长上下文、长时 Agents 持续降本

New		
隐式缓存	扩展缓存	显式缓存
		
存储： KV cache 内存态 (in-mem)	存储： 本地 SSD，限单 GPU 节点	存储： 专建的 Azure 资源，Context Cache
理念： 默认即快 (Fast by default)	理念： 可控的性能 (Controlled perf)	理念： 把缓存当作核心系统组件
适用负载： 快速多轮会话、agents、特性开关、实时统计	适用负载： 聊天、媒体资产、搜索索引、ML 特征、CI 产物	适用负载： 长上下文/多轮对话、长时运行的 agents、全球化内容、分析结果、跨区复用
数据规模： KB–MB	数据规模： MB–GB	数据规模： 无大小限制
TTL： 5–10 分钟 (最长 1 小时)	TTL： 最长 24 小时	TTL： 数天到数周乃至数月
价值： 快、简单	价值： 高性价比的规模化	价值： 企业自有的缓存持久化、全球覆盖
API： 由模型提供方持有缓存与 API	API： 由模型提供方持有缓存与 API	API： 由推理引擎 (inference engine) 持有